

11.06.2026

Makine Öğrenmesi Yöntemleri ile Kredi Risk Seviyesi Sınıflandırması ve Faiz Oranı Tahmini

Veri Madenciliği Final Projesi

Aslı Serife Sertcelik-25221001018
TOPKAPI UNIVERSITESI YAPAY ZEKA YUKSEK LISANS
TEZLI

Makine Öğrenmesi Yöntemleri ile Kredi Risk Seviyesi Sınıflandırması ve Faiz Oranı Tahmini

Aslı Şerife Sertçelik
Yazılım Mühendisliği Anabilim Dalı, Yapay Zeka Tezli Yüksek Lisansı
İstanbul Topkapı Üniversitesi,
İstanbul, Türkiye
25221001018

asli.serife.sertcelik@std.topkapi.edu.tr

Veri Madenciliği Vize-Final Çalışma - Colab

Abstract— Bu çalışmada makine öğrenmesi yöntemleri kullanarak kredi risk seviyesi sınıflandırması ve faiz oranı tahmini gerçekleştirilmiştir. Finans sektöründe kredi değerlendirme süreçlerinin hızlandırılması, riskli müşterilerin erken tespit edilmesi ve finansal karar mekanizmalarının iyileştirilmesi büyük önem taşımaktadır. Geleneksel kredi değerlendirme yöntemleri çoğu zaman manuel süreçlere dayanmakta ve yüksek miktardaki finansal verinin etkin şekilde analiz edilmesinde yetersiz kalabilmektedir. Bu nedenle veri madenciliği ve makine öğrenmesi tabanlı yöntemler finansal risk analizi alanında yaygın şekilde kullanılmaya başlanmıştır.

Çalışmada müşterilere ait kredi başvuru bilgileri, gelir düzeyi, borç oranı, kredi sorgu geçmişi, hesap bilgileri ve faiz oranı verilerinden oluşan bir finansal veri seti kullanılmıştır. Veri ön işleme aşamasında eksik veriler analiz edilmiş, kategorik değişkenlere Label Encoding yöntemi uygulanmış, aykırı değer analizleri gerçekleştirilmiş ve veri ölçekleme işlemleri uygulanmıştır. Ayrıca keşifsel veri analizi (EDA) kapsamında değişken dağılımları, korelasyon ilişkileri ve finansal değişkenler arasındaki örüntüler incelenmiştir.

Sınıflandırma aşamasında müşterilerin kredi risk seviyelerini tahmin etmek amacıyla Logistic Regression, Decision Tree, AdaBoost ve Gradient Boosting algoritmaları uygulanmıştır. Modeller accuracy, precision, recall, F1-score ve ROC-AUC metrikleri kullanılarak değerlendirilmiştir. Elde edilen sonuçlar Gradient Boosting algoritmasının diğer modellere göre daha başarılı performans gösterdiğini ortaya koymuştur. Özellikle ROC eğrileri ve confusion matrix sonuçları modelin risk gruplarını daha başarılı şekilde ayırt edebildiğini göstermiştir.

Regresyon aşamasında ise müşterilere uygulanacak faiz oranlarının tahmini amacıyla Linear Regression modeli kullanılmıştır. Regresyon sonuçları finansal değişkenler ile faiz oranları arasında belirli ilişkiler bulunduğunu göstermiştir. Ancak düşük R^2 değeri (0.14) finansal verilerde doğrusal olmayan ilişkilerin bulunduğunu ortaya koymuştur.

Elde edilen sonuçlar makine öğrenmesi yöntemlerinin bankacılık, fintech, risk yönetimi ve varlık yönetim şirketleri gibi alanlarda kredi riski analizi ve faiz tahmini problemlerinde etkili şekilde kullanılabileceğini göstermektedir.

Keywords: *Machine Learning, Data Mining, Credit Risk, Interest Rate Prediction, Classification, Regression, Gradient Boosting, Financial Risk Analysis*

I. GİRİŞ

Finans sektörü, dijital dönüşüm ve büyük veri teknolojilerinin gelişmesiyle birlikte veri odaklı karar verme süreçlerine hızla adapte olmaktadır. Özellikle bankacılık ve finans kuruluşları açısından kredi riskinin doğru şekilde analiz edilmesi, müşteri davranışlarının değerlendirilmesi ve uygun faiz oranlarının belirlenmesi kritik öneme sahiptir. Geleneksel kredi değerlendirme süreçleri çoğu zaman manuel analizlere ve sınırlı finansal göstergelere dayanmaktadır. Ancak günümüzde müşteri sayısının ve finansal işlem hacminin hızla artması, bu yöntemlerin yetersiz kalmasına neden olmaktadır. Bu durum veri madenciliği ve makine öğrenmesi tabanlı sistemlerin finans sektöründe yaygın olarak kullanılmasını zorunlu hale getirmiştir.

Makine öğrenmesi algoritmaları büyük ölçekli finansal veriler içerisindeki karmaşık örüntüleri analiz ederek müşterilerin kredi risk seviyelerini tahmin edebilmekte ve finansal karar süreçlerine destek sağlayabilmektedir. Özellikle kredi başvurularının değerlendirilmesi, riskli müşterilerin erken tespiti, faiz oranlarının belirlenmesi ve müşteri segmentasyonu gibi alanlarda yapay zeka destekli sistemler önemli avantajlar sunmaktadır. Finansal veri setleri çoğunlukla doğrusal olmayan ilişkiler, eksik veriler, aykırı değerler ve sınıf dengesizliği gibi problemler içermektedir. Bu nedenle veri ön işleme, özellik mühendisliği ve uygun makine öğrenmesi algoritmalarının seçimi model performansı açısından büyük önem taşımaktadır.

Kredi riski analizi üzerine gerçekleştirilen çalışmalarda Logistic Regression, Decision Tree, Random Forest, AdaBoost ve Gradient Boosting gibi algoritmalar yaygın olarak kullanılmaktadır. Özellikle boosting tabanlı algoritmalar, finansal veri setlerindeki karmaşık ilişkileri öğrenme konusunda başarılı sonuçlar üretmektedir. Bunun yanında regresyon modelleri de müşterilere uygulanacak faiz oranlarının tahmin edilmesinde önemli rol oynamaktadır. Finansal risk analizi sistemlerinin başarısı yalnızca yüksek doğruluk oranlarına değil, aynı zamanda farklı risk gruplarını dengeli şekilde ayırt edebilmesine bağlıdır. Bu nedenle Accuracy, Precision, Recall, F1-score

ve ROC-AUC gibi performans metrikleri birlikte değerlendirilmektedir.

Bu çalışmada makine öğrenmesi yöntemleri kullanılarak müşterilerin kredi risk seviyelerinin sınıflandırılması ve faiz oranlarının tahmin edilmesi amaçlanmıştır. Çalışmada finansal müşteri verilerinden oluşan bir veri seti kullanılmıştır. Veri ön işleme aşamasında eksik veriler analiz edilmiş, kategorik değişkenler dönüştürülmüş, aykırı değer analizleri gerçekleştirilmiş ve veri ölçekleme işlemleri uygulanmıştır. Keşifsel Veri Analizi (EDA) kapsamında finansal değişkenler arasındaki ilişkiler incelenmiş ve veri seti içerisindeki örüntüler analiz edilmiştir.

Sınıflandırma aşamasında Logistic Regression, Decision Tree, AdaBoost ve Gradient Boosting algoritmaları uygulanmıştır. Modellerin performansları karşılaştırılmış ve en başarılı model belirlenmiştir. Regresyon aşamasında ise müşterilere uygulanacak faiz oranlarının tahmini amacıyla Linear Regression modeli kullanılmıştır. Elde edilen sonuçlar makine öğrenmesi yöntemlerinin bankacılık, fintech, risk yönetimi ve varlık yönetim şirketleri gibi alanlarda etkin şekilde kullanılabileceğini göstermektedir.

II. İLGİLİ ÇALIŞMALAR VE LİTERATÜR TARAMASI

Finansal risk analizi, kredi skorlama ve faiz tahmini problemleri son yıllarda veri madenciliği ve makine öğrenmesi alanlarında yoğun şekilde araştırılmaktadır. Bankacılık sektöründe dijital dönüşümün hızlanmasıyla birlikte büyük ölçekli müşteri verilerinin analiz edilmesi ve kredi risklerinin erken aşamada tahmin edilmesi kritik hale gelmiştir. Bu nedenle geleneksel istatistiksel yöntemlerin yanında yapay zeka ve makine öğrenmesi tabanlı modeller finansal karar destek sistemlerinde yaygın şekilde kullanılmaya başlanmıştır.

Erken dönem kredi risk tahmin çalışmalarında çoğunlukla istatistiksel yöntemler ve doğrusal modeller kullanılmıştır. Özellikle Logistic Regression modeli, kredi değerlendirme sistemlerinde uzun yıllar temel yöntemlerden biri olarak tercih edilmiştir. Logistic Regression modeli yorumlanabilirliği yüksek olmasına rağmen karmaşık finansal örüntüleri öğrenme konusunda sınırlı kalabilmektedir. Finansal veri setlerinin doğrusal olmayan yapıya sahip olması nedeniyle daha gelişmiş makine öğrenmesi algoritmalarına ihtiyaç duyulmuştur.

Karar ağacı tabanlı algoritmalar finansal veri madenciliği çalışmalarında yaygın şekilde kullanılmaktadır. Decision Tree algoritmaları müşteri davranışlarını yorumlanabilir kurallar halinde modelleyebilmekte ve kredi risk seviyelerinin belirlenmesinde etkili sonuçlar sunabilmektedir. Ancak tek başına karar ağaçları aşırı öğrenme (overfitting) problemi nedeniyle bazı veri setlerinde kararsız sonuçlar üretebilmektedir. Bu problemi azaltmak amacıyla ensemble learning yöntemleri geliştirilmiştir.

Ensemble learning yaklaşımları, birden fazla zayıf öğreniciyi birleştirerek daha güçlü tahmin modelleri oluşturmayı amaçlamaktadır. Özellikle AdaBoost ve Gradient Boosting algoritmaları finansal risk analizi alanında başarılı sonuçlar üretmektedir. AdaBoost algoritması yanlış sınıflandırılan örneklerle daha fazla ağırlık vererek model performansını artırmayı hedeflemektedir.

Gradient Boosting algoritması ise ardışık öğrenme yaklaşımı ile önceki modellerin hatalarını minimize ederek yüksek doğruluk oranları elde edebilmektedir. Literatürde boosting tabanlı modellerin kredi skorlama ve risk sınıflandırma problemlerinde geleneksel yöntemlere göre daha başarılı sonuçlar ürettiği belirtilmektedir.

Finansal veri setlerinde sıklıkla karşılaşılan önemli problemlerden biri eksik veri ve aykırı değer problemidir. Eksik verilerin uygun yöntemlerle doldurulmaması model performansını olumsuz etkileyebilmektedir. Bunun yanında finansal veriler çoğunlukla sağa çarpık dağılımlar ve yüksek varyans içermektedir. Bu nedenle veri ön işleme aşamasında veri temizleme, ölçekleme ve aykırı değer analizi kritik önem taşımaktadır. Literatürde StandardScaler ve MinMaxScaler gibi veri ölçekleme yöntemlerinin model performansını artırdığı belirtilmektedir.

Kredi riski tahmini çalışmalarında yalnızca sınıflandırma problemleri değil, aynı zamanda faiz oranı tahmini gibi regresyon problemleri de önemli araştırma alanları arasında yer almaktadır. Regresyon modelleri müşterilerin finansal özellikleri ile uygulanacak faiz oranları arasındaki ilişkileri analiz etmek amacıyla kullanılmaktadır. Özellikle Linear Regression modeli finansal değişkenler arasındaki doğrusal ilişkilerin analiz edilmesinde temel yöntemlerden biri olarak kullanılmaktadır. Ancak finansal verilerin karmaşık yapısı nedeniyle doğrusal olmayan ilişkilerin de dikkate alınması gerekmektedir.

Son yıllarda finans sektöründe geliştirilen yapay zeka destekli sistemler yalnızca bankacılık alanında değil; fintech şirketleri, sigorta şirketleri, varlık yönetim şirketleri ve dijital kredi platformlarında da kullanılmaktadır. Bu sistemler sayesinde müşterilerin ödeme davranışları analiz edilmekte, kredi riskleri tahmin edilmekte ve otomatik karar destek mekanizmaları geliştirilmektedir.

Bu çalışma, kredi risk seviyesi sınıflandırması ve faiz oranı tahmini problemlerini birlikte ele alması açısından literatürdeki birçok çalışmadan ayrılmaktadır. Çalışmada veri ön işleme, keşifsel veri analizi, feature engineering, boosting tabanlı sınıflandırma algoritmaları ve regresyon modelleri birlikte kullanılarak kapsamlı bir finansal veri madenciliği yaklaşımı sunulmuştur. Özellikle Gradient Boosting algoritmasının performansının detaylı şekilde değerlendirilmesi çalışmanın temel katkılarından birini oluşturmaktadır.

III. METODOLOJİ VE UYGULAMA ADIMLARI

Bu çalışmanın metodolojisi finansal müşteri verilerinin analiz edilmesi, veri ön işleme süreçlerinin uygulanması, keşifsel veri analizi (EDA), özellik mühendisliği (feature engineering), sınıflandırma ve regresyon modellerinin eğitilmesi olmak üzere ardışık ve sistemli aşamalardan oluşmaktadır. Her bir işlem adımı, model performansını artırmak, veri setindeki finansal örüntüleri ortaya çıkarmak ve gerçek dünya senaryolarında daha başarılı tahminler elde edebilmek amacıyla özel olarak tasarlanmıştır.

Çalışma boyunca veri madenciliği süreçlerinde akademik literatürde yaygın olarak kullanılan veri temizleme, veri dönüşümü, veri ölçekleme ve ensemble learning yaklaşımları dikkate alınmıştır. Özellikle finansal veri setlerinde sık karşılaşılan eksik veri, aykırı değer ve

doğrusal olmayan ilişki problemlerinin giderilmesine yönelik veri ön işleme stratejileri uygulanmıştır.

A. Veri Setinin Yapısı ve Veri Ön İşleme

Çalışmada kullanılan veri seti, müşterilere ait kredi başvuru bilgileri, gelir düzeyi, borç oranı, kredi sorgu geçmişi, hesap bilgileri ve faiz oranı değişkenlerinden oluşmaktadır. Veri seti toplam 164,309 gözlem ve 14 değişkenden meydana gelmektedir. Veri setinde hem sayısal hem de kategorik değişkenler bulunmaktadır.

Veri madenciliği süreçlerinin sağlıklı şekilde yürütülebilmesi amacıyla veri seti üzerinde detaylı ön inceleme gerçekleştirilmiştir. İlk aşamada eksik veriler analiz edilmiş ve eksik değer oranları belirlenmiştir. Özellikle Months_Since_Delinquency değişkeninde yüksek oranda eksik veri bulunduğu gözlemlenmiştir. Finansal açıdan değerlendirildiğinde, bu eksik değerlerin müşterilerin gecikmeli ödeme geçmişine sahip olmamasından kaynaklanabileceği düşünülmüş ve ilgili değişken sıfır değeri ile doldurulmuştur.


Bunun yanında Annual_Income, Home_Owner ve Length_Employed gibi değişkenlerde bulunan eksik veriler uygun istatistiksel yöntemler kullanılarak tamamlanmıştır. Sayısal değişkenlerde ortalama değer kullanılırken, kategorik değişkenlerde mod değeri tercih edilmiştir.

Makine öğrenmesi modellerinin kategorik değişkenleri işleyebilmesi amacıyla kategorik sütunlara Label Encoding yöntemi uygulanmıştır. Bu işlem sonucunda metinsel ifadeler sayısal etiketlere dönüştürülmüş ve veri seti modelleme aşamasına uygun hale getirilmiştir.

B. Keşifsel Veri Analizi (EDA)


İkinci aşamada veri seti üzerinde Keşifsel Veri Analizi (Exploratory Data Analysis-EDA) gerçekleştirilmiştir. Bu süreçte veri setinin dağılım yapısı, değişkenler arasındaki ilişkiler ve finansal örüntüler incelenmiştir.

Gelir dağılımı histogramları incelendiğinde veri setinin sağa çarpık (right-skewed) dağılım sergilediği gözlemlenmiştir. Bu durum finansal veri setlerinde sıklıkla karşılaşılan bir yapı olup, yüksek gelirli müşteri gruplarının ortalamayı yukarı çekmesinden kaynaklanmaktadır.




Şekil 1. Gelir Dağılımı Histogramı

Faiz oranı dağılımı analiz edildiğinde bazı risk sınıflarının veri setinde daha baskın olduğu görülmüştür. Bu durum sınıf dengesizliği probleminin model performansı üzerindeki etkisini ortaya koymuştur.



Şekil 2. Faiz Oranı Dağılımı

Korelasyon matrisi analizleri sonucunda özellikle Number_Open_Accounts ile Total_Accounts değişkenleri arasında güçlü pozitif ilişki bulunduğu gözlemlenmiştir. Bunun yanında Debt_To_Income ve Inquiries_Last_6Mo değişkenlerinin faiz oranı ile pozitif ilişki gösterdiği belirlenmiştir. Bu sonuçlar yüksek borç oranı ve yoğun kredi sorgu geçmişine sahip müşterilerin daha yüksek risk grubunda değerlendirilebileceğini göstermektedir.




Şekil 3. Correlation Matrix

C. Aykırı Değer Analizi ve Veri Ölçekleme

Finansal veri setlerinde yüksek varyans ve aykırı değer problemleri model performansını olumsuz etkileyebilmektedir. Bu nedenle veri seti üzerinde Boxplot grafikleri kullanılarak aykırı değer analizleri gerçekleştirilmiştir.

Özellikle gelir düzeyi, açık hesap sayısı ve toplam hesap sayısı değişkenlerinde aykırı gözlemler bulunduğu gözlemlenmiştir. Aykırı değerlerin belirlenmesinde Interquartile Range (IQR) yöntemi kullanılmıştır. Ancak finansal veri setlerinde uç değerlerin gerçek müşteri davranışlarını temsil edebilmesi nedeniyle veri kaybını önlemek amacıyla aykırı değerler veri setinden tamamen çıkarılmamıştır.



Şekil 4: Aykırı Değer Analizi (Boxplot)

Makine öğrenmesi algoritmalarının değişken ölçeklerinden etkilenmesini önlemek amacıyla StandardScaler yöntemi kullanılarak veri ölçekleme işlemi uygulanmıştır. Bu işlem sonucunda değişkenler standart normal dağılıma yaklaştırılmış ve model eğitim sürecinin daha kararlı hale gelmesi sağlanmıştır.

D. Özellik Mühendisliği (Feature Engineering)

Makine öğrenmesi modellerinin başarısını doğrudan etkileyen en önemli aşamalardan biri özellik mühendisliği (feature engineering) sürecidir. Özellik mühendisliği; mevcut ham verilerden yeni ve anlamlı değişkenler türeterek modellerin veri içerisindeki karmaşık örüntüleri daha başarılı öğrenmesini amaçlamaktadır. Özellikle finansal veri setlerinde müşterilerin davranışsal eğilimlerini doğrudan temsil eden değişkenlerin oluşturulması model performansını önemli ölçüde artırabilmektedir.

Bu çalışmada finansal risk analizi problemini daha güçlü temsil edebilmek amacıyla mevcut değişkenlerden yeni finansal göstergeler türetilmiştir. Oluşturulan yeni özellikler müşterilerin borç yükü, kredi kullanım davranışı, finansal yoğunluğu ve risk eğilimleri hakkında daha detaylı bilgi sağlamaktadır.

İlk olarak müşterilerin finansal yükünü temsil etmek amacıyla debt_income_ratio değişkeni oluşturulmuştur. Bu değişken müşterinin toplam borç düzeyinin gelirine oranlanmasıyla elde edilmiştir. Finans literatüründe borç/gelir oranı kredi riskini belirlemede en kritik göstergelerden biri olarak kabul edilmektedir. Yüksek borç/gelir oranına sahip müşterilerin ödeme güçlüğü yaşama ihtimalinin daha yüksek olduğu bilinmektedir.

Bunun yanında müşterilerin kredi başvuru yoğunluğu ile finansal yükünü birlikte değerlendirebilmek amacıyla risk_score isimli yeni bir özellik oluşturulmuştur. Bu değişken oluşturulurken kredi sorgu geçmişi (Inquiries_Last_6Mo) ve borç oranı (Debt_To_Income) birlikte değerlendirilmiştir. Böylece hem yoğun kredi başvurusu yapan hem de yüksek borç yüküne sahip müşterilerin daha riskli profiller oluşturduğu varsayılmıştır.

Ayrıca müşterilerin finansal hesap kullanım davranışlarını incelemek amacıyla credit_utilization değişkeni türetilmiştir. Bu değişken açık hesap sayısı (Number_Open_Accounts) ile toplam hesap sayısı (Total_Accounts) arasındaki ilişkiyi temsil etmektedir. Hesap kullanım yoğunluğunun yüksek olması müşterinin finansal hareketliliği hakkında önemli bilgiler sunabilmektedir.

Feature Engineering sürecinde yalnızca yeni değişkenler oluşturulmamış, aynı zamanda değişkenlerin dağılım yapıları da incelenmiştir. Özellikle gelir düzeyi ve hesap sayıları gibi bazı finansal değişkenlerin sağa çarpık (right-skewed) dağılım sergilediği gözlemlenmiştir. Bu tür dağılımlar makine öğrenmesi modellerinin öğrenme sürecini olumsuz etkileyebilmektedir. Bu nedenle bazı değişkenler üzerinde ölçekleme ve dönüşüm işlemleri uygulanarak veri dağılımı daha dengeli hale getirilmiştir.

Özellik mühendisliği aşaması sonucunda veri seti yalnızca ham finansal kayıtlar içeren bir yapıdan çıkarılarak müşterilerin finansal davranışlarını daha güçlü temsil eden gelişmiş bir özellik matrisine dönüştürülmüştür. Bu dönüşüm sayesinde özellikle boosting tabanlı algoritmaların veri içerisindeki karmaşık ilişkileri daha başarılı şekilde öğrenmesi sağlanmıştır.

Gerçekleştirilen deneysel çalışmalar sonucunda feature engineering işlemlerinin model performansı üzerinde olumlu etkiler oluşturduğu gözlemlenmiştir. Özellikle risk odaklı yeni değişkenlerin eklenmesiyle birlikte sınıflandırma modellerinin kredi risk seviyelerini ayırt etme başarısında artış meydana gelmiştir.

E. Veri Bölümleme ve Modelleme Süreci

Makine öğrenmesi modellerinin gerçek dünya performanslarının tarafsız şekilde değerlendirilebilmesi amacıyla veri seti eğitim (train) ve test (test) olmak üzere iki temel alt kümeye ayrılmıştır. Veri bölme işlemi sırasında veri setinin %80'i eğitim verisi, %20'si ise test verisi olarak kullanılmıştır. Bu işlem sırasında random_state=42 parametresi kullanılarak deneysel sonuçların tekrarlanabilir olması sağlanmıştır.

Sınıflandırma problemlerinde veri dağılımının korunması model performansı açısından kritik öneme sahiptir. Bu nedenle veri bölme işlemi sırasında hedef değişkenin sınıf dağılımının korunmasına dikkat edilmiştir. Eğitim veri seti model öğrenme sürecinde kullanılırken, test veri seti modelin daha önce görmediği veriler üzerindeki başarısını ölçmek amacıyla kullanılmıştır.

Veri bölme işlemi sonrasında makine öğrenmesi modellerinin ölçek farklılıklarından etkilenmesini önlemek amacıyla StandardScaler yöntemi uygulanmıştır. Standardizasyon işlemi sayesinde değişkenler ortak ölçek aralığına taşınmış ve özellikle doğrusal modellerin daha kararlı öğrenmesi sağlanmıştır.

Bu yaklaşım sayesinde modellerin aşırı öğrenme (overfitting) problemi azaltılmış ve gerçek dünya koşullarını daha başarılı temsil eden sonuçlar elde edilmiştir.

Kullanılan Sınıflandırma Modelleri

Bu çalışmada kredi risk seviyelerinin tahmin edilmesi amacıyla Logistic Regression, Decision Tree, AdaBoost ve Gradient Boosting algoritmaları kullanılmıştır. Logistic Regression modeli temel karşılaştırma (baseline) modeli olarak tercih edilmiş, Decision Tree algoritması ise karar kurallarının yorumlanabilirliğini değerlendirmek amacıyla kullanılmıştır. Ensemble learning yaklaşımını temsil eden AdaBoost ve Gradient Boosting algoritmaları ise daha yüksek tahmin performansı elde etmek amacıyla modele dahil edilmiştir.

Logistic Regression,

Değişkenler ile hedef sınıf arasındaki doğrusal ilişkiyi modelleyen temel bir sınıflandırma algoritmasıdır. Decision Tree algoritması ise veriyi belirli karar kurallarına göre bölerek sınıflandırma gerçekleştirmektedir.

Decision Tree (Karar Ağacı)

Verileri belirli kurallara göre dallara ayırarak sınıflandırma yapan denetimli makine öğrenmesi yöntemlerinden biridir. Algoritma, her düğümde veriyi en iyi şekilde ayıran özelliği seçerek karar ağacı yapısını oluşturur ve yaprak düğümlerde nihai sınıflandırma sonucunu üretir. Karar ağaçlarının en önemli avantajlarından biri, model tarafından verilen kararların kolay yorumlanabilmesidir.

Bu çalışmada Decision Tree algoritması, kredi risk seviyelerinin belirlenmesinde temel sınıflandırma yöntemlerinden biri olarak kullanılmıştır. Model, müşterilerin finansal özelliklerini kullanarak kredi risk sınıflarını tahmin etmiş ve diğer makine öğrenmesi algoritmaları ile performans karşılaştırmasına dahil edilmiştir. Elde edilen sonuçlar, Decision Tree modelinin veri setindeki temel örüntüleri öğrenebildiğini ancak daha karmaşık ilişkileri modellemede AdaBoost ve Gradient Boosting gibi ensemble yöntemlerin gerisinde kaldığını göstermiştir

AdaBoost (Adaptive Boosting)

algoritması, hatalı sınıflandırılan örneklerle daha fazla ağırlık vererek ardışık öğrenme gerçekleştiren bir ensemble learning yöntemidir. Çalışmada başlangıçta varsayılan parametrelerle eğitilmiş, daha sonra GridSearchCV yöntemi kullanılarak hiperparametre optimizasyonu uygulanmıştır. Optimizasyon sonucunda en uygun parametreler learning_rate = 1.0 ve n_estimators = 200 olarak belirlenmiştir.

Gradient Boosting

Her yeni modelin bir önceki model tarafından yapılan hataları öğrenmesi prensibine dayanmaktadır. Bu yöntem özellikle karmaşık ve doğrusal olmayan ilişkilerin bulunduğu veri setlerinde başarılı sonuçlar vermektedir. Çalışmada kullanılan başlangıç parametreleri n_estimators = 100, learning_rate = 0.1 ve max_depth = 3 olarak belirlenmiştir. GridSearchCV ile gerçekleştirilen hiperparametre optimizasyonu sonucunda aynı parametre kombinasyonunun en iyi performansı sağladığı görülmüştür.

Hiperparametre Optimizasyonu

Modellerin performansını artırmak amacıyla AdaBoost ve Gradient Boosting algoritmaları üzerinde GridSearchCV tabanlı hiperparametre optimizasyonu gerçekleştirilmiştir. Bu süreçte farklı parametre kombinasyonları sistematik olarak denenmiş ve 3-Katlı Çapraz Doğrulama (3-Fold Cross Validation) yöntemi kullanılarak en uygun parametreler belirlenmiştir.


Elde edilen sonuçlar, AdaBoost modelinde doğruluk oranının 0.5150'den 0.5208'e yükseldiğini göstermiştir. Gradient Boosting modelinde ise optimizasyon öncesi ve sonrası doğruluk değerleri birbirine oldukça yakın bulunmuş ve başlangıç parametrelerinin veri seti için zaten uygun olduğu görülmüştür. Bu sonuçlar, hiperparametre optimizasyonunun model seçim sürecini doğrulamak ve algoritmaların performans sınırlarını değerlendirmek açısından önemli katkılar sağladığını göstermektedir.

Model	Accuracy
AdaBoost (Varsayılan)	0.5151
AdaBoost (Optimize Edilmiş)	0.5208

Tablo 1: AdaBoost Hiperparametre Öncesi ve Sonrası

Model	Accuracy
Gradient Boosting (Varsayılan)	0.5333
Gradient Boosting (GridSearchCV)	0.5332

Tablo 2: GradientBoost Hiperparametre Öncesi ve Sonrası



Şekil.5: GridSearch Öncesi ve Sonrası Model Performansları

K-Fold Cross Validation

Makine öğrenmesi modellerinin farklı veri alt kümeleri üzerindeki performansını daha güvenilir şekilde değerlendirebilmek amacıyla K-Fold Cross Validation (K-Katlı Çapraz Doğrulama) yöntemi uygulanmıştır. Bu yöntemde veri seti eşit büyüklükte K parçaya ayrılmakta ve her iterasyonda bir parça doğrulama verisi olarak kullanılırken kalan parçalar eğitim verisi olarak kullanılmaktadır. Bu işlem tüm parçalar doğrulama verisi olarak kullanılıncaya kadar tekrarlanmaktadır.

Bu çalışmada 5-Fold Cross Validation yöntemi tercih edilmiştir. Böylece model performansı yalnızca tek bir train-test bölünmesine bağlı kalmadan farklı veri alt kümeleri üzerinde test edilmiş ve daha güvenilir sonuçlar elde edilmiştir. Ayrıca çapraz doğrulama yöntemi sayesinde veri bölünmesinden kaynaklanabilecek yanlılıkların azaltılması ve modelin genelleme yeteneğinin değerlendirilmesi amaçlanmıştır.

Gradient Boosting modeli üzerinde gerçekleştirilen 5-Katlı Çapraz Doğrulama sonucunda doğruluk değerleri sırasıyla 0.4281, 0.5342, 0.5375, 0.5366 ve 0.4297 olarak elde edilmiştir. Ortalama doğruluk değeri ise 0.4932 olarak hesaplanmıştır. Sonuçlar modelin farklı veri alt kümelerinde genel olarak tutarlı performans gösterdiğini ancak veri setindeki heterojen yapı nedeniyle katlar arasında belirli performans farklılıkları oluşabildiğini göstermektedir.

Fold	Accuracy
Fold 1	0.4281
Fold 2	0.5342
Fold 3	0.5375
Fold 4	0.5366
Fold 5	0.4297
Ortalama	0.4932

Tablo.3: 5 Katlı Çapraz Doğrulama Tablosu

F. Sınıflandırma Modellerinin Eğitimi ve Performans Analizi

Çalışmanın sınıflandırma aşamasında müşterilerin kredi risk seviyelerini tahmin etmek amacıyla farklı makine öğrenmesi algoritmaları kullanılmıştır. İlk aşamada temel karşılaştırma modeli (baseline model) olarak Logistic Regression algoritması uygulanmıştır. Logistic Regression modeli doğrusal yapısı sayesinde finansal değişkenler arasındaki temel ilişkilerin analiz edilmesine olanak sağlamıştır.

Bunun yanında doğrusal olmayan finansal ilişkilerin modellenenebilmesi amacıyla Decision Tree algoritması kullanılmıştır. Decision Tree modeli veri içerisindeki karar kurallarını öğrenerek müşteri risk seviyelerini sınıflandırmıştır. Ancak karar ağacı yapılarının aşırı öğrenmeye yatkın olması nedeniyle daha gelişmiş ensemble learning yöntemlerine ihtiyaç duyulmuştur.

Bu doğrultuda boosting tabanlı AdaBoost ve Gradient Boosting algoritmaları modele dahil edilmiştir. AdaBoost algoritması yanlış sınıflandırılan örnekler daha fazla ağırlık vererek model performansını artırmayı hedeflemiştir. Gradient Boosting algoritması ise önceki modellerin hatalarını minimize edecek şekilde ardışık öğrenme yaklaşımı kullanarak daha güçlü tahminler üretmiştir.

Modellerin performans değerlendirmesinde:

- Accuracy,
- Precision,
- Recall,
- F1-score,
- ROC-AUC

metrikleri kullanılmıştır.

Confusion Matrix analizleri sayesinde modellerin hangi risk gruplarında başarılı veya yetersiz kaldığı detaylı şekilde incelenmiştir. ROC Curve analizleri ise modellerin sınıfları ayırt etme başarısını değerlendirmek amacıyla kullanılmıştır.

Gerçekleştirilen deneysel çalışmalar sonucunda boosting tabanlı modellerin diğer algoritmalara göre daha başarılı sonuçlar ürettiği gözlemlenmiştir. Özellikle Gradient Boosting algoritması:

- en yüksek accuracy değerini,
- en dengeli sınıflandırma performansını,

- en başarılı ROC-AUC sonuçlarını

üretmek çalışmanın en başarılı sınıflandırma modeli olmuştur.

Model karşılaştırma sonuçları, boosting tabanlı ensemble learning yaklaşımlarının finansal veri setlerindeki karmaşık örüntüleri daha başarılı öğrenebildiğini göstermektedir.

G. Regresyon Modelleri ve Faiz Tahmini

Çalışmanın regresyon aşamasında müşterilere uygulanacak faiz oranlarının tahmin edilmesi amaçlanmıştır. Finans sektöründe faiz oranlarının doğru şekilde belirlenmesi, kredi risk yönetimi ve müşteri segmentasyonu açısından büyük önem taşımaktadır. Geleneksel faiz belirleme süreçleri çoğu zaman sabit finansal kurallara dayalı olarak yürütülmektedir. Ancak müşteri davranışlarının karmaşık yapısı nedeniyle makine öğrenmesi tabanlı regresyon modelleri daha esnek ve veri odaklı çözümler sunabilmektedir.

Bu çalışmada faiz oranı tahmini problemi için Linear Regression algoritması kullanılmıştır. Model oluşturulurken bağımsız değişkenler olarak müşterilerin:

- gelir düzeyi (Annual_Income),
- borç oranı (Debt_To_Income),
- kredi sorgu geçmişi (Inquiries_Last_6Mo),
- açık hesap sayısı (Number_Open_Accounts),
- toplam hesap sayısı (Total_Accounts),
- kredi kullanım davranışları

gibi finansal değişkenleri kullanılmıştır.

Model eğitimi sonrasında regresyon performansı farklı hata metrikleri kullanılarak değerlendirilmiştir.

Elde edilen sonuçlar aşağıda verilmiştir:

- Mean Absolute Error (MAE): **MAE = 0.5704**
- Mean Squared Error (MSE): **MSE = 0.4748**
- Root Mean Squared Error (RMSE): **RMSE = 0.6891**
- Determination Coefficient (R^2 Score): **$R^2 = 0.1308$**

MAE sonucunun düşük seviyede olması modelin genel tahmin hatalarının kabul edilebilir düzeyde olduğunu göstermektedir. Bunun yanında RMSE değerinin MAE değerinden daha yüksek olması veri setinde bazı uç tahmin hatalarının bulunduğunu ortaya koymaktadır. Finansal veri setlerinde müşteri davranışlarının heterojen yapısı nedeniyle bu durum beklenen bir sonuç olarak değerlendirilmektedir.

Regresyon analizleri sonucunda özellikle:

- yüksek borç oranına sahip müşterilerin,
 - yoğun kredi sorgu geçmişi bulunan bireylerin,
 - finansal hesap hareketliliği yüksek olan müşterilerin
- daha yüksek faiz oranları ile ilişkilendirildiği gözlemlenmiştir.

Modelin R^2 skorunun düşük seviyede kalması, finansal değişkenler ile faiz oranları arasındaki ilişkilerin tamamen doğrusal olmadığını göstermektedir. Bu durum finans


sektöründeki müşteri davranışlarının karmaşık ve çok boyutlu yapısından kaynaklanmaktadır. Özellikle finansal risk analizlerinde müşterilerin davranışsal eğilimleri, ödeme alışkanlıkları ve piyasa koşulları gibi doğrusal olmayan birçok faktör faiz oranlarını etkileyebilmektedir.

Bununla birlikte regresyon modeli faiz oranlarının genel eğilimini başarılı şekilde tahmin edebilmiş ve finansal veri setindeki temel ilişkileri ortaya koymuştur. Elde edilen sonuçlar makine öğrenmesi tabanlı regresyon modellerinin:


- bankacılık sistemlerinde,
- fintech uygulamalarında,
- kredi değerlendirme süreçlerinde,
- varlık yönetim şirketlerinde

faiz tahmini ve risk analizi amacıyla kullanılabileceğini göstermektedir.


Gerçekleştirilen deneysel çalışmalar sonucunda regresyon modellerinin finansal karar destek sistemleri açısından anlamlı çıktılar üretebildiği ve daha gelişmiş ensemble learning tabanlı regresyon modelleri ile performansın artırılabilirliği değerlendirilmiştir.



Şekil 6.a: Gerçek ve Tahmin Edilen Faiz Oranlarının Dağılımı (Scatter Plot)




Şekil 6.b: Gerçek ve Tahmin Edilen Faiz Oranlarının Dağılımı (Box Plot)



Şekil 6.b: Gerçek ve Tahmin Edilen Faiz Oranlarının Dağılımı (Histogram)

a. Logistic Regression Confusion Matrix


Şekil 7’de Logistic Regression modeline ait confusion matrix gösterilmektedir. Modelin özellikle orta risk grubundaki müşterileri daha başarılı sınıflandırdığı, düşük ve yüksek risk gruplarında ise hata oranlarının arttığı gözlemlenmiştir.



Şekil 7: Logistic Regression Confusion Matrix

b. Decision Tree Confusion Matrix


Şekil 8’de Decision Tree modeline ait confusion matrix verilmiştir. Modelin bazı sınıflarda dengesiz tahminler ürettiği ve aşırı öğrenme eğilimi gösterdiği gözlemlenmiştir.



Şekil 8: Decision Tree Confusion Matrix

c. AdaBoost Confusion Matrix


Şekil 9’da AdaBoost modeline ait confusion matrix yer almaktadır. Ensemble learning yaklaşımı sayesinde sınıf bazındaki tahmin başarısının önceki modellere göre daha dengeli hale geldiği görülmektedir.



Şekil 9: AdaBoost Confusion Matrix

d. Gradient Boosting Confusion Matrix

Şekil 10’da Gradient Boosting modeline ait confusion matrix gösterilmektedir. Diyagonal üzerindeki yüksek değerler modelin tüm sınıflarda daha başarılı tahminler ürettiğini göstermektedir. Özellikle yüksek risk grubundaki müşterilerin sınıflandırılmasında belirgin performans artışı elde edilmiştir.




Şekil 10: Gradient Boosting Confusion Matrix

ROC Curve İçin de aynı yapı söz konusudur.

a. Logistic Regression ROC Curve

Şekil 11’de Logistic Regression modeline ait ROC eğrileri gösterilmektedir. ROC eğrilerinin referans çizgisinin üzerinde konumlanması modelin rastgele tahmine göre daha başarılı sonuçlar ürettiğini göstermektedir. Ortalama AUC


değerinin 0.74 olarak elde edilmesi, modelin kredi risk seviyelerini ayırt etme konusunda kabul edilebilir bir performans sergilediğini ortaya koymaktadır. Bununla birlikte eğrilerin ideal üst sol köşeye yeterince yaklaşamaması, Logistic Regression modelinin veri setindeki karmaşık ve doğrusal olmayan ilişkileri tam olarak yakalayamadığını göstermektedir



Şekil 11: Logistic Regression ROC Curve

b. Decision Tree ROC Curve

Şekil 12’de Decision Tree modeline ait ROC eğrileri yer almaktadır. Ortalama AUC değerinin 0.59 olarak hesaplanması, modelin sınıfları ayırt etme başarısının diğer modellere kıyasla daha düşük olduğunu göstermektedir. ROC eğrilerinin referans çizgisine yakın seyretmesi, Decision Tree algoritmasının veri setindeki karmaşık örüntüleri öğrenmekte sınırlı kaldığını göstermektedir. Buna rağmen modelin karar mekanizmasının yorumlanabilir olması, kredi risk analizinde hangi değişkenlerin etkili olduğunu incelemek açısından önemli avantaj sağlamaktadır.




Şekil 12: Decision Tree ROC Curve

c. AdaBoost ROC Curve

Şekil 13’de AdaBoost modeline ait ROC eğrileri gösterilmektedir. Ortalama AUC değerinin 0.75 olarak elde edilmesi, AdaBoost algoritmasının kredi risk seviyelerini ayırt etme konusunda başarılı performans sergilediğini göstermektedir. Eğrilerin referans çizgisinden belirgin


şekilde uzaklaşması, modelin doğru pozitif oranını artırırken yanlış pozitif oranını kontrol altında tutabildiğini ortaya koymaktadır. Sonuçlar, AdaBoost algoritmasının birden fazla zayıf öğreniciyi birleştirerek tekil modellerden daha güçlü bir sınıflandırma performansı sağlayabildiğini göstermektedir.



Şekil 13: Adaboost ROC Curve

d. Gradient Boosting ROC Curve

Şekil 14’de Gradient Boosting modeline ait ROC eğrileri sunulmaktadır. Ortalama AUC değerinin 0.84 olarak elde edilmesi, çalışmada kullanılan modeller arasında en yüksek ayırt edicilik performansının Gradient Boosting algoritmasına ait olduğunu göstermektedir. ROC eğrilerinin üst sol köşeye daha yakın konumlanması, modelin farklı kredi risk seviyelerini başarılı şekilde ayırt edebildiğini ortaya koymaktadır. Bu sonuç, Gradient Boosting algoritmasının önceki modellerin hatalarını öğrenerek performansını kademeli olarak geliştirmesi ve karmaşık finansal ilişkileri etkili biçimde modelleyebilmesi ile açıklanabilir. Elde edilen bulgular, Gradient Boosting modelinin bu veri seti üzerinde en başarılı sınıflandırma yöntemi olduğunu desteklemektedir.



Şekil 14: Gradient Boosting ROC curve

Model	Ortalama AUC
Logistic Regression	0.74
Decision Tree	0.59
AdaBoost	0.75
Gradient Boosting	0.84

Tablo 4: Modellerin AUC Performans Karşılaştırması

Tablo 4 incelendiğinde en yüksek ortalama AUC değerinin 0.84 ile Gradient Boosting modeline ait olduğu görülmektedir. AdaBoost (0.75) ve Logistic Regression (0.74) modelleri benzer performans sergilerken, Decision Tree modeli 0.59 AUC değeri ile en düşük ayırt edicilik performansını göstermiştir. Sonuçlar, ensemble learning tabanlı yöntemlerin kredi risk sınıflandırmasında daha başarılı sonuçlar ürettiğini ortaya koymaktadır.

H. Feature Engineering Etkisinin Değerlendirilmesi

Model	Açıklama	Accuracy
Model 1	Feature Engineering Öncesi	0.5303
Model 2	Feature Engineering Sonrası	0.5333
<i>İyileşme</i>	-	<i>+0.003</i>

Tablo 5: Feature Engineering Etkisi

Feature engineering öncesinde Gradient Boosting modelinin doğruluk oranı %53.03 olarak elde edilirken, feature engineering sonrasında bu değer %53.33'e yükselmiştir.

Feature engineering aşamasında debt_income_ratio, risk_score ve credit_utilization olmak üzere üç yeni değişken oluşturulmuştur. Bu değişkenler müşterilerin borç yükünü, kredi başvuru davranışlarını ve kredi kullanım alışkanlıklarını daha iyi temsil etmeyi amaçlamaktadır.

Daha sonraki feature importance analizlerinde debt_income_ratio değişkeninin en önemli özellikler arasında yer aldığı gözlemlenmiştir. Bu sonuç, oluşturulan yeni değişkenlerin modelin karar verme sürecine katkı sağladığını göstermektedir.

Özellikle finansal veri madenciliği uygulamalarında alan bilgisi kullanılarak oluşturulan türetilmiş değişkenlerin model performansını artırabildiği ve risk değerlendirme süreçlerini daha açıklanabilir hale getirebildiği görülmektedir.

IV. DENEYSEL SONUÇ VE TARTIŞMA

Bu bölümde sınıflandırma ve regresyon modellerinden elde edilen deneysel sonuçlar değerlendirilmiş ve modellerin performansları karşılaştırılmıştır. Çalışmada kullanılan makine öğrenmesi algoritmalarının kredi risk seviyelerini

tahmin etme başarıları farklı performans metrikleri kullanılarak analiz edilmiştir.

Sınıflandırma problemlerinde modellerin başarısını değerlendirmek amacıyla:

- Accuracy,
- Precision,
- Recall,
- F1-score,
- ROC-AUC

metriklerinden yararlanılmıştır. Ayrıca Confusion Matrix ve ROC Curve analizleri ile modellerin sınıf bazındaki performansları detaylı şekilde incelenmiştir.

A. Logistic Regression Sonuçları

Çalışmanın ilk sınıflandırma modeli olarak Logistic Regression algoritması uygulanmıştır. Logistic Regression modeli finansal değişkenler arasındaki temel doğrusal ilişkileri öğrenebilmiş ancak karmaşık örüntüleri modelleme konusunda sınırlı performans göstermiştir.

Model sonucunda elde edilen accuracy değeri:

$$Accuracy = 0.4947$$

olarak hesaplanmıştır.

Confusion Matrix analizleri incelendiğinde modelin özellikle orta risk grubundaki müşterileri daha başarılı sınıflandırdığı gözlemlenmiştir. Bununla birlikte düşük ve yüksek risk gruplarında sınıflandırma performansının sınırlı kaldığı belirlenmiştir.

ROC eğrileri değerlendirildiğinde modelin sınıfları ayırt etme başarısının orta seviyede olduğu görülmüştür. Logistic Regression modelinin doğrusal yapısı nedeniyle finansal veri setlerindeki karmaşık ilişkileri tam olarak öğrenemediği değerlendirilmiştir.

B. Decision Tree Sonuçları

Decision Tree algoritması veri içerisindeki karar kurallarını öğrenerek müşterilerin kredi risk seviyelerini sınıflandırmıştır. Karar ağacı yapısı sayesinde model yorumlanabilir sonuçlar üretmiş ve değişkenler arasındaki ilişkileri kurallar halinde modelleyebilmiştir.

Decision Tree modeli sonucunda elde edilen accuracy değeri:

$$Accuracy = 0.4305$$

olarak hesaplanmıştır.

Confusion Matrix sonuçları Decision Tree modelinin bazı sınıflarda dengesiz tahminler ürettiğini göstermiştir. Özellikle veri setindeki karmaşık finansal örüntüler nedeniyle modelin aşırı öğrenme (overfitting) eğilimi gösterdiği değerlendirilmiştir.

ROC analizleri sonucunda modelin sınıfları ayırt etme başarısının Logistic Regression modeline benzer seviyede kaldığı gözlemlenmiştir. Bu durum tekil karar ağacı yapılarının finansal veri setlerinde sınırlı performans gösterebildiğini ortaya koymaktadır.

C. AdaBoost Sonuçları

Boosting tabanlı ensemble learning yöntemlerinden biri olan AdaBoost algoritması çalışmaya dahil edilmiştir. AdaBoost modeli yanlış sınıflandırılan örnekler daha fazla ağırlık vererek model performansını artırmayı hedeflemiştir. Model sonucunda elde edilen accuracy değeri:

$$Accuracy = 0.5150$$

olarak hesaplanmıştır.

AdaBoost modeli özellikle orta ve yüksek risk gruplarındaki müşterilerin sınıflandırılmasında önceki modellere göre daha başarılı sonuçlar üretmiştir. Confusion Matrix analizleri modelin sınıf bazındaki tahmin başarısının daha dengeli hale geldiğini göstermiştir.

ROC eğrileri değerlendirildiğinde AdaBoost algoritmasının sınıfları ayırt etme başarısının Logistic Regression ve Decision Tree modellerine göre daha yüksek olduğu belirlenmiştir. Ensemble learning yaklaşımının finansal veri setlerindeki karmaşık ilişkileri öğrenme konusunda avantaj sağladığı görülmüştür.

D. Gradient Boosting Sonuçları

Çalışmanın en başarılı sınıflandırma modeli Gradient Boosting algoritması olmuştur. Gradient Boosting modeli ardışık öğrenme yaklaşımı kullanarak önceki modellerin hatalarını minimize etmiş ve finansal veri setindeki karmaşık örüntüleri daha başarılı şekilde öğrenmiştir.

Model sonucunda elde edilen accuracy değeri:

$$Accuracy = 0.5333$$

olarak hesaplanmıştır.

Classification Report sonuçları incelendiğinde:

- precision,
- recall,
- F1-score

değerlerinin diğer modellere göre daha dengeli olduğu görülmüştür.

Özellikle yüksek risk grubundaki müşterilerin tahmin başarısında belirgin artış gözlemlenmiştir. Confusion Matrix analizleri modelin tüm sınıflarda daha başarılı tahminler ürettiğini göstermiştir.

ROC Curve analizleri sonucunda:

- düşük risk,
- orta risk,
- yüksek risk

grupları için elde edilen AUC değerlerinin diğer modellere göre daha yüksek olduğu belirlenmiştir.

Gradient Boosting algoritmasının:

- doğrusal olmayan ilişkileri öğrenebilmesi,
- hata minimizasyonuna dayalı yapısı,
- ensemble learning yaklaşımı

nedeniyle finansal veri setlerinde daha başarılı performans ürettiği değerlendirilmiştir.

E. Regresyon Sonuçlarının Değerlendirilmesi

Faiz oranı tahmini amacıyla oluşturulan Linear Regression modeli finansal değişkenler ile faiz oranları arasındaki ilişkileri analiz etmek amacıyla kullanılmıştır. Regresyon modelinden elde edilen sonuçlar:

- MAE: $MAE = 0.5704$
- RMSE: $RMSE = 0.6891$
- R² Score: $R^2 = 0.1308$

olarak hesaplanmıştır.

Sonuçlar finansal veri setlerinde faiz oranlarını etkileyen çok sayıda karmaşık faktör bulunduğunu göstermektedir. Düşük R² değeri doğrusal modellerin finansal örüntüleri tam olarak temsil etmekte sınırlı kalabileceğini ortaya koymuştur.

Bununla birlikte model faiz oranlarının genel eğilimini başarılı şekilde tahmin edebilmiş ve finansal değişkenler arasındaki temel ilişkileri ortaya çıkarmıştır.

Genel olarak değerlendirildiğinde boosting tabanlı sınıflandırma algoritmalarının finansal risk analizi problemlerinde daha başarılı performans gösterdiği, regresyon modellerinin ise faiz tahmini açısından anlamlı sonuçlar üretebildiği sonucuna ulaşılmıştır.

Feature Importance analizleri sonucunda Gradient Boosting modelinin karar mekanizmasında en etkili değişkenlerin sırasıyla Loan_Amount_Requested, Income_Verified, Inquiries_Last_6Mo, Purpose_Of_Loan ve debt_income_ratio olduğu belirlenmiştir

Sıra	Değişken	Importance
1	Loan_Amount_Requested	0.1804
2	Income_Verified	0.1771
3	Inquiries_Last_6Mo	0.1649
4	Purpose_Of_Loan	0.1335
5	debt_income_ratio	0.1275

Tablo. 6: Gradient Boosting Modeline Ait Feature Importance Sonuçları

.Özellikle talep edilen kredi miktarının (Loan_Amount_Requested) en yüksek önem değerine sahip olması, kredi risk seviyesinin belirlenmesinde kredi talebinin büyüklüğünün kritik rol oynadığını göstermektedir. Gelir doğrulama durumu (Income_Verified) ve son altı aydaki kredi sorgu sayısı (Inquiries_Last_6Mo) değişkenlerinin de yüksek önem değerleri göstermesi, müşterilerin finansal güvenilirliği ve kredi kullanım davranışlarının risk değerlendirmesinde önemli göstergeler olduğunu ortaya koymaktadır.

Feature engineering aşamasında oluşturulan debt_income_ratio değişkeninin üst sıralarda yer alması, yeni türetilen değişkenlerin model performansına anlamlı katkı sağladığını göstermektedir. Elde edilen sonuçlar, kredi risk analizinde yalnızca temel finansal göstergelerin değil, aynı zamanda türetilmiş davranışsal göstergelerin de dikkate alınması gerektiğini ortaya koymaktadır.


V. MODEL KARŞILAŞTIRMA VE FİNANSAL DEĞERLENDİRME

Bu bölümde çalışmada kullanılan makine öğrenmesi modellerinin performansları karşılaştırılmış ve finansal risk analizi açısından elde edilen sonuçlar değerlendirilmiştir. Modellerin başarı düzeyleri yalnızca accuracy değeri üzerinden değil; precision, recall, F1-score, ROC-AUC ve confusion matrix analizleri dikkate alınarak çok boyutlu şekilde incelenmiştir.

Gerçekleştirilen deneysel çalışmalar sonucunda kullanılan sınıflandırma algoritmalarının performans değerleri Tablo 7'de ve şekil 14'te gösterilmektedir.

Model	Accuracy
Logistic Regression	0.4947
Decision Tree	0.4305
AdaBoost	0.5150
AdaBoost (Optimize)	0.5208
Gradient Boosting	0.5333
Gradient Boosting (Optimize)	0.5332

Tablo.7: Modellere Ait Performans Değerleri



Şekil.14: Classification Model Accuracy Comparison

Model	Accuracy	AUC
Logistic Regression	0.4947	0.74
Decision Tree	0.4305	0.59
AdaBoost	0.5151	0.75
Gradient Boosting	0.5333	0.84

Tablo.8: Modellerin Accuracy-AUC Karşılaştırması

Tablo 8 sonuçları incelendiğinde en başarılı performansın Gradient Boosting algoritması ile elde edildiği görülmektedir. Gradient Boosting modeli:

- en yüksek accuracy değerine,
- en dengeli sınıflandırma performansına,
- en başarılı ROC sonuçlarına ulaşmıştır.

Özellikle boosting tabanlı algoritmaların finansal veri setlerindeki doğrusal olmayan ilişkileri daha başarılı şekilde öğrenebildiği gözlemlenmiştir. Finansal müşteri davranışlarının karmaşık yapısı nedeniyle ensemble learning yöntemlerinin klasik doğrusal modellere göre daha başarılı performans ürettiği değerlendirilmiştir.

Logistic Regression modeli temel doğrusal ilişkileri öğrenebilmiş olsa da finansal veri setlerindeki karmaşık örüntüleri modelleme konusunda sınırlı kalmıştır. Decision Tree modeli ise yorumlanabilir sonuçlar üretmesine rağmen aşırı öğrenme eğilimi nedeniyle daha düşük performans göstermiştir.

AdaBoost algoritması yanlış sınıflandırılan örnekler ağırlık vererek önceki modellere göre daha başarılı sonuçlar üretmiştir. Ancak en başarılı sonuçlar Gradient Boosting algoritması ile elde edilmiştir. Gradient Boosting modeli hata minimizasyonuna dayalı ardışık öğrenme yaklaşımı sayesinde risk gruplarını daha başarılı şekilde ayırt edebilmiştir.

ROC Curve analizleri incelendiğinde Gradient Boosting modelinin düşük, orta ve yüksek risk gruplarında daha yüksek ayırt edicilik performansı gösterdiği belirlenmiştir. Özellikle yüksek risk grubundaki müşterilerin tahmin edilmesinde boosting tabanlı algoritmaların önemli avantaj sağladığı görülmüştür.

Finansal değerlendirme açısından analiz edildiğinde:

- yüksek borç oranına sahip müşterilerin,
- yoğun kredi sorgu geçmişi bulunan bireylerin,
- gelir düzeyi düşük müşterilerin,
- hesap hareketliliği yüksek olan bireylerin

daha yüksek risk grubunda sınıflandırıldığı gözlemlenmiştir. Bunun yanında feature engineering aşamasında oluşturulan:

- debt_income_ratio,
- risk_score,

- credit_utilization

gibi yeni değişkenlerin model performansını olumlu etkilediği değerlendirilmiştir.

Çalışma sonuçları makine öğrenmesi yöntemlerinin:

- bankacılık sistemlerinde,
- fintech uygulamalarında,
- kredi değerlendirme süreçlerinde,
- varlık yönetim şirketlerinde,
- finansal karar destek sistemlerinde

etkin şekilde kullanılabileceğini göstermektedir.

Özellikle boosting tabanlı ensemble learning algoritmalarının finansal risk analizi problemlerinde güçlü performans sergilediği ve gerçek dünya uygulamalarında kullanılabilecek seviyede sonuçlar üretebildiği sonucuna ulaşılmıştır.

VI. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada makine öğrenmesi yöntemleri kullanılarak kredi risk seviyesi sınıflandırması ve faiz oranı tahmini gerçekleştirilmiştir. Çalışmanın temel amacı; müşterilerin finansal risk seviyelerini analiz etmek, faiz oranlarını tahmin etmek ve finansal veri madenciliği yöntemlerinin kredi değerlendirme süreçlerindeki etkinliğini incelemektir.

Çalışma kapsamında finansal müşteri verilerinden oluşan veri seti üzerinde kapsamlı veri ön işleme süreçleri uygulanmıştır. Eksik veriler analiz edilmiş, kategorik değişkenler dönüştürülmüş, aykırı değer analizleri gerçekleştirilmiş ve veri ölçekleme işlemleri uygulanmıştır. Ayrıca Keşifsel Veri Analizi (EDA) ile veri seti içerisindeki finansal örüntüler, değişken ilişkileri ve dağılım yapıları incelenmiştir.

Sınıflandırma aşamasında Logistic Regression, Decision Tree, AdaBoost ve Gradient Boosting algoritmaları kullanılmıştır. Modeller Accuracy, Precision, Recall, F1-score ve ROC-AUC metrikleri kullanılarak değerlendirilmiştir. Deneysel sonuçlar boosting tabanlı ensemble learning algoritmalarının finansal veri setlerinde daha başarılı performans gösterdiğini ortaya koymuştur.

Özellikle Gradient Boosting modeli:

- en yüksek accuracy değerine,
- en başarılı ROC performansına,
- en dengeli sınıflandırma sonuçlarına

ulaşarak çalışmanın en başarılı sınıflandırma modeli olmuştur.

Regresyon aşamasında kullanılan Linear Regression modeli müşterilere uygulanacak faiz oranlarının genel eğilimini tahmin edebilmiştir. Bununla birlikte düşük R^2 değeri finansal veri setlerinde doğrusal olmayan ilişkilerin önemli düzeyde bulunduğunu göstermiştir.

Feature Importance analizleri sonucunda:

- Loan_Amount_Requested,
- Income_Verified,
- Inquiries_Last_6Mo,
- debt_income_ratio

gibi değişkenlerin model kararları üzerinde yüksek etkiye sahip olduğu belirlenmiştir. Bu sonuçlar müşterilerin borç yükü, gelir doğrulama durumu ve kredi başvuru yoğunluğunun finansal risk analizi açısından kritik değişkenler olduğunu göstermektedir.

Çalışma sonuçları makine öğrenmesi yöntemlerinin:

- bankacılık sistemlerinde,
- fintech uygulamalarında,
- varlık yönetim şirketlerinde,
- kredi değerlendirme süreçlerinde,
- finansal karar destek sistemlerinde

etkin şekilde kullanılabileceğini ortaya koymaktadır.

Gelecek Çalışmalar

Bu çalışmada temel ve boosting tabanlı makine öğrenmesi algoritmaları kullanılmıştır. Gelecek çalışmalarda:

- XGBoost,
- LightGBM,
- CatBoost,
- Deep Learning tabanlı yapılar,
- yapay sinir ağları (ANN),
- Explainable AI yöntemleri

kullanılarak model performansı daha ileri seviyeye taşınabilir.

Bunun yanında:

- gerçek zamanlı kredi değerlendirme sistemleri,
- büyük ölçekli finansal veri analizi,
- müşteri davranış tahmini,
- fraud detection sistemleri,
- otomatik faiz optimizasyonu

gibi alanlarda daha kapsamlı çalışmalar gerçekleştirilebilir. Ayrıca SHAP, LIME ve gelişmiş Explainable AI yöntemleri kullanılarak modellerin karar mekanizmaları daha detaylı şekilde yorumlanabilir hale getirilebilir.

Sonuç olarak bu çalışma, makine öğrenmesi yöntemlerinin finansal risk analizi ve faiz tahmini problemlerinde güçlü ve uygulanabilir çözümler sunduğunu göstermektedir.

REFERENCES

- [1] T. Hastie, R. Tibshirani, and J. Friedman, The Elements of Statistical Learning: Data Mining, Inference, and Prediction, 2nd ed., Springer, 2009.
- [2] J. Han, M. Kamber, and J. Pei, Data Mining: Concepts and Techniques, 3rd ed., Morgan Kaufmann, 2011.
- [3] C. M. Bishop, Pattern Recognition and Machine Learning, Springer, 2006.

- [4] S. Lessmann, B. Baesens, H. V. Seow, and L. C. Thomas, "Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research," *European Journal of Operational Research*, vol. 247, no. 1, pp. 124–136, 2015.
- [5] J. H. Friedman, "Greedy Function Approximation: A Gradient Boosting Machine," *Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [6] Y. Freund and R. E. Schapire, "A Decision-Theoretic Generalization of On-Line Learning and an Application to Boosting," *Journal of Computer and System Sciences*, vol. 55, no. 1, pp. 119–139, 1997.
- [7] B. Baesens, *Analytics in a Big Data World: The Essential Guide to Data Science and its Applications*, Wiley, 2014.
- [8] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [10] Kaggle, "Loan Prediction Dataset," Available: <https://www.kaggle.com/>
- [11] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pp. 785–794, 2016.
- [12] G. Ke et al., "LightGBM: A Highly Efficient Gradient Boosting Decision Tree," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [13] L. Breiman, "Random Forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [14] D. Dua and C. Graff, "UCI Machine Learning Repository," University of California, Irvine, School of Information and Computer Sciences, 2019.
- [15] S. Raschka and V. Mirjalili, *Python Machine Learning*, 3rd ed., Packt Publishing, 2019.